SVM: 가장 넓은 차선 찾기의 마법

복잡한 수식 없이 직관으로 이해하는 서포트 벡터 머신 (Support Vector Machine)의 원리

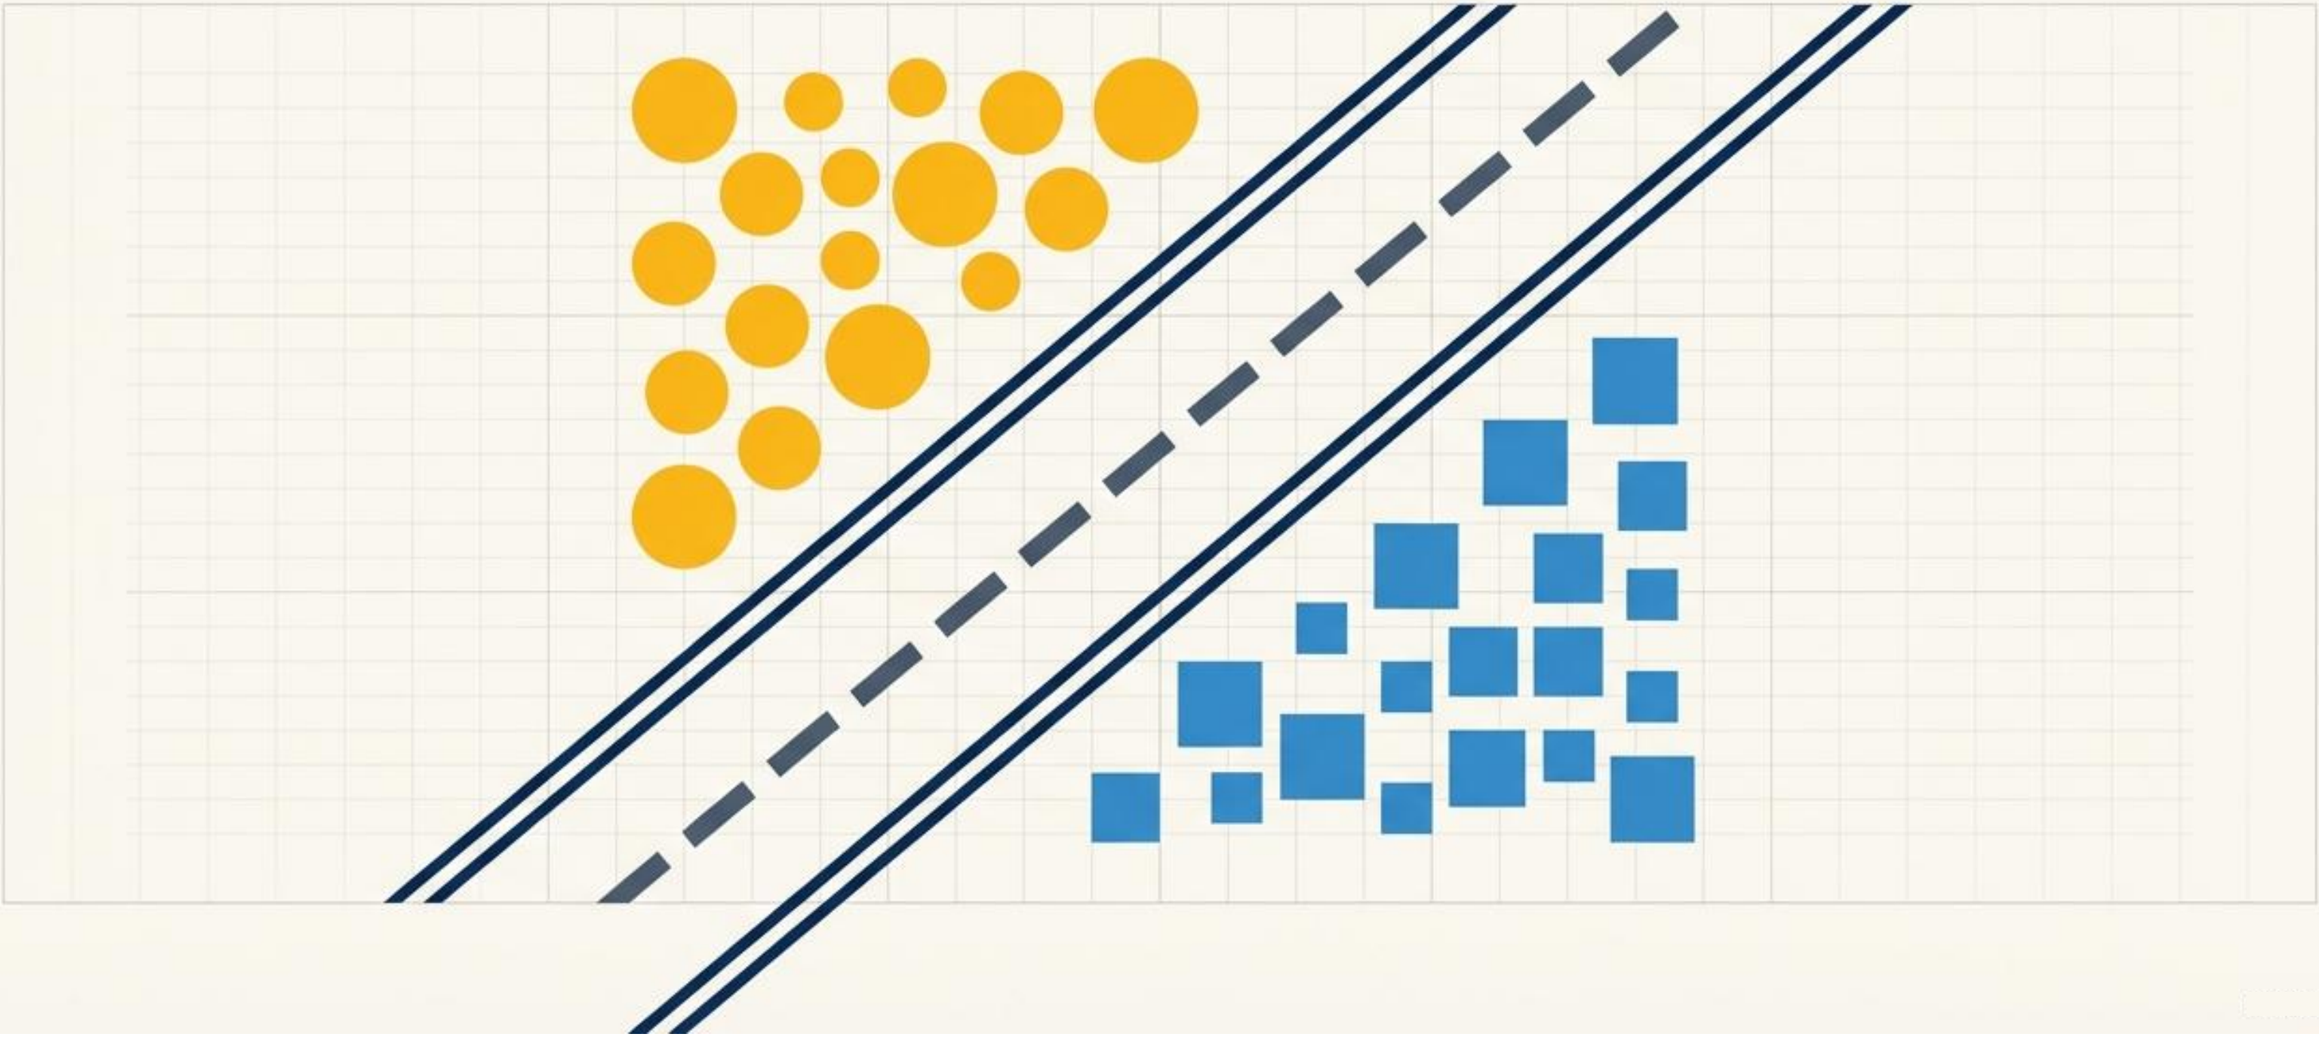

머신러닝의 도시 계획: 두 동네를 가르는 가장 넓은 도로 만들기

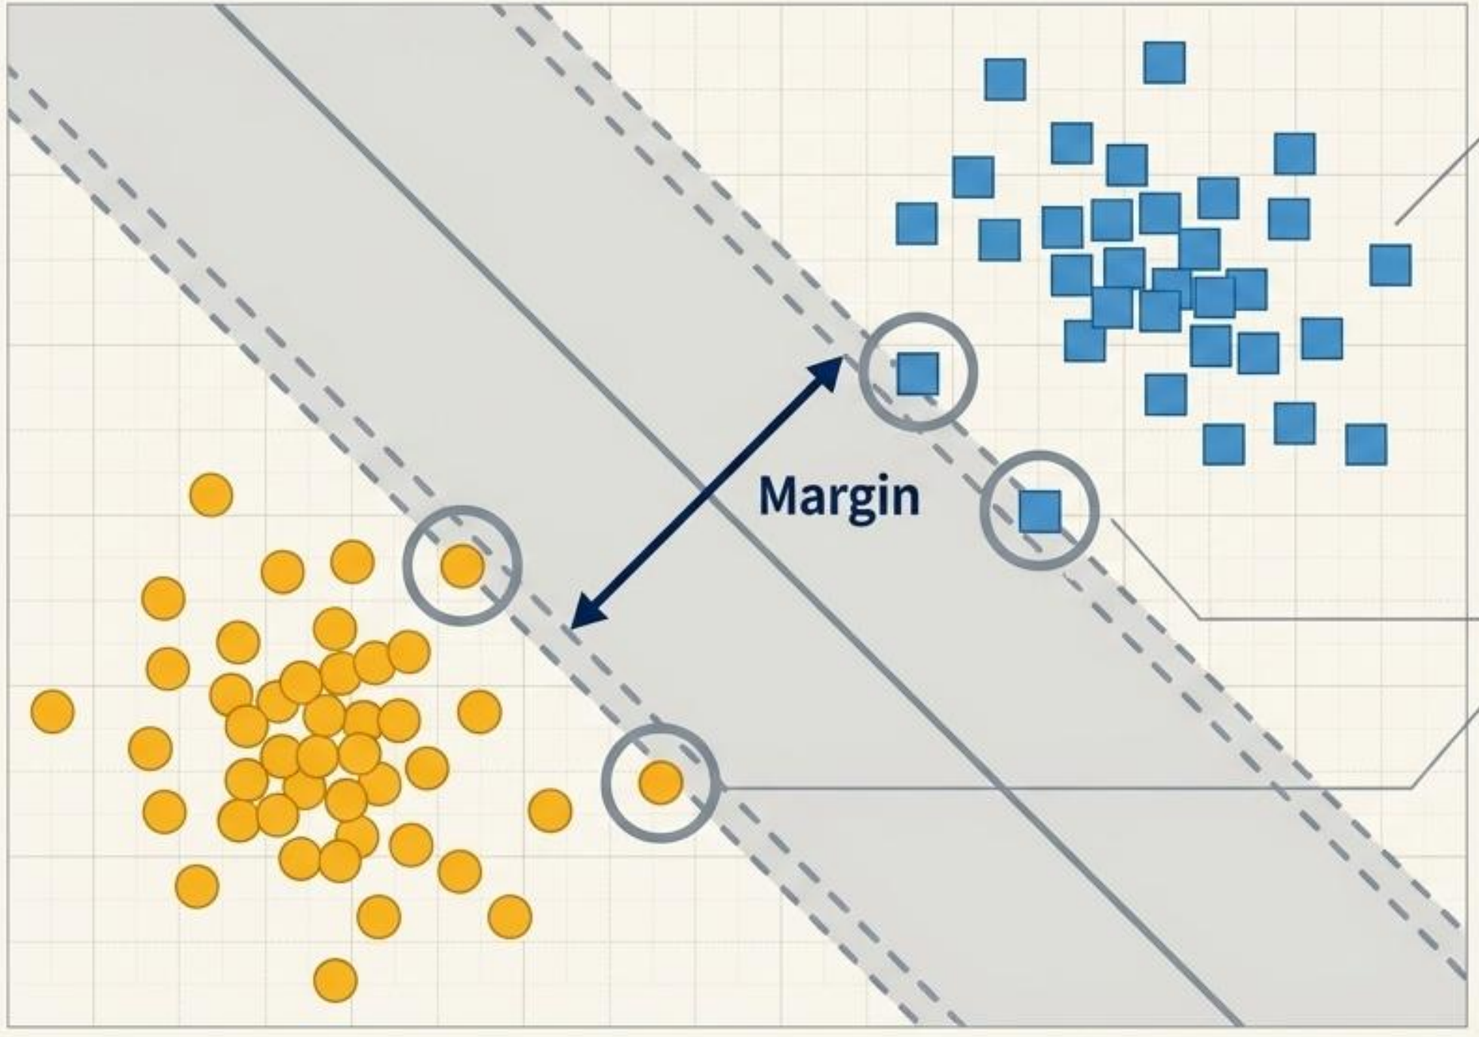

라지 마진 분류 (Large Margin Classification)

단순히 두 그룹을 나누는 선을 긋는 것이 아니라, 가능한 한 가장 넓은 텅 빈 공간(도로)을 확보하는 것이 SVM의 목표입니다.

서포트 벡터 (Support Vector)

도로의 경계에 아슬아슬하게 걸쳐 있는 핵심 샘플들입니다. 오직 이 샘플들만이 도로의 폭과 방향을 결정합니다. 다른 데이터는 도로의 위치에 영향을 주지 않습니다.

완벽한 도로 설계를 위한 절대 법칙: 특성 스케일링

스케일되지 않음 (Unscaled)

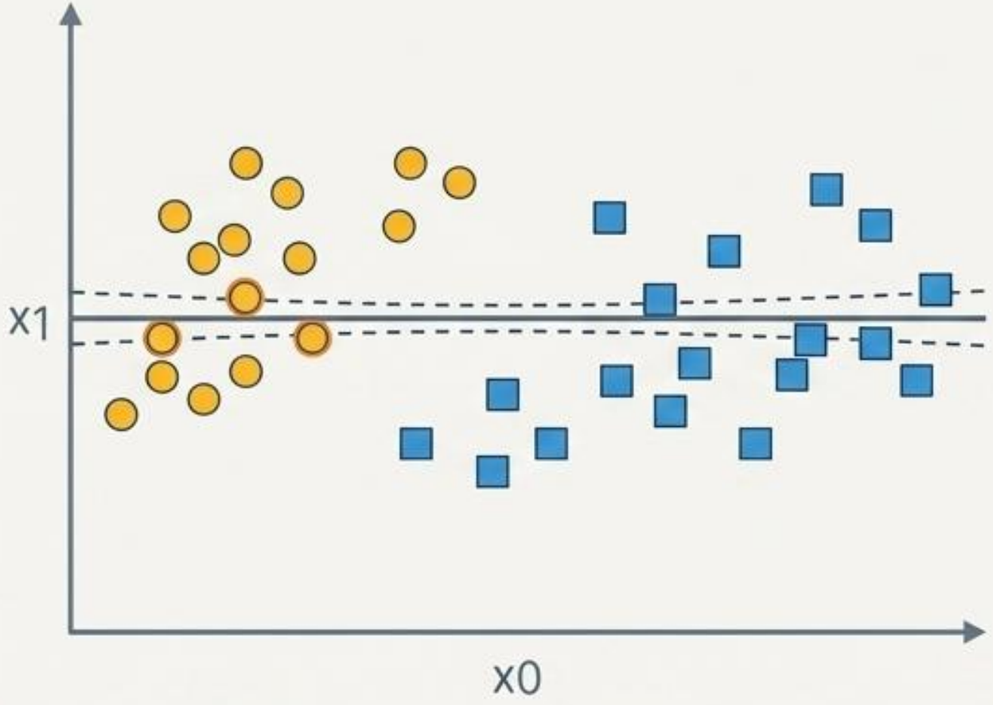

데이터의 축(단위) 비율이 다르면, 도로는 스케일이 작은 축을 따라 한쪽으로 심하게 찌그러집니다.

스케일됨 (Scaled)

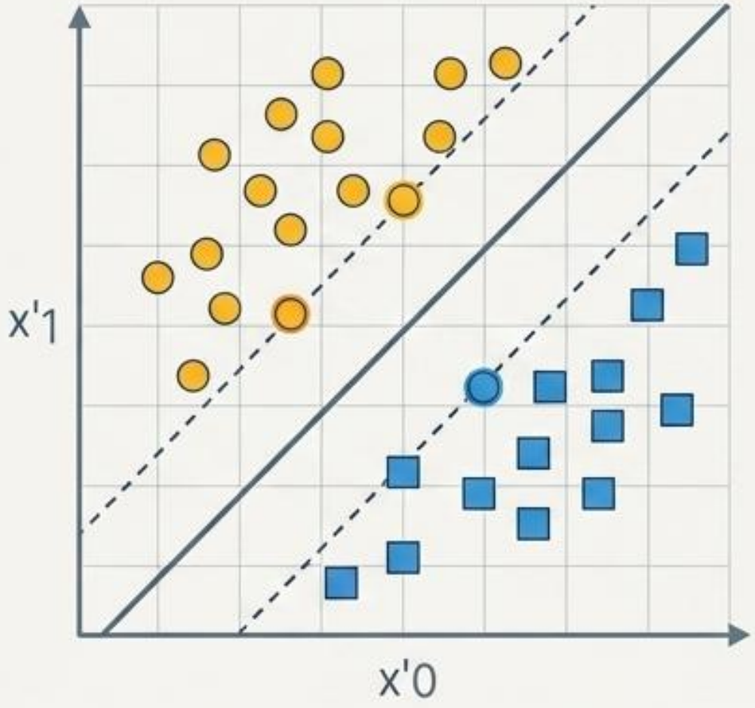

StandardScaler 등을 사용해 데이터의 스케일을 맞추면, 훨씬 넓고 안정적인 최적의 결정 경계를 찾을 수 있습니다.

현실 세계의 혼돈: 단단한 도로(Hard Margin)의 한계

분류 불가능한 상황 (Impossible Separation)

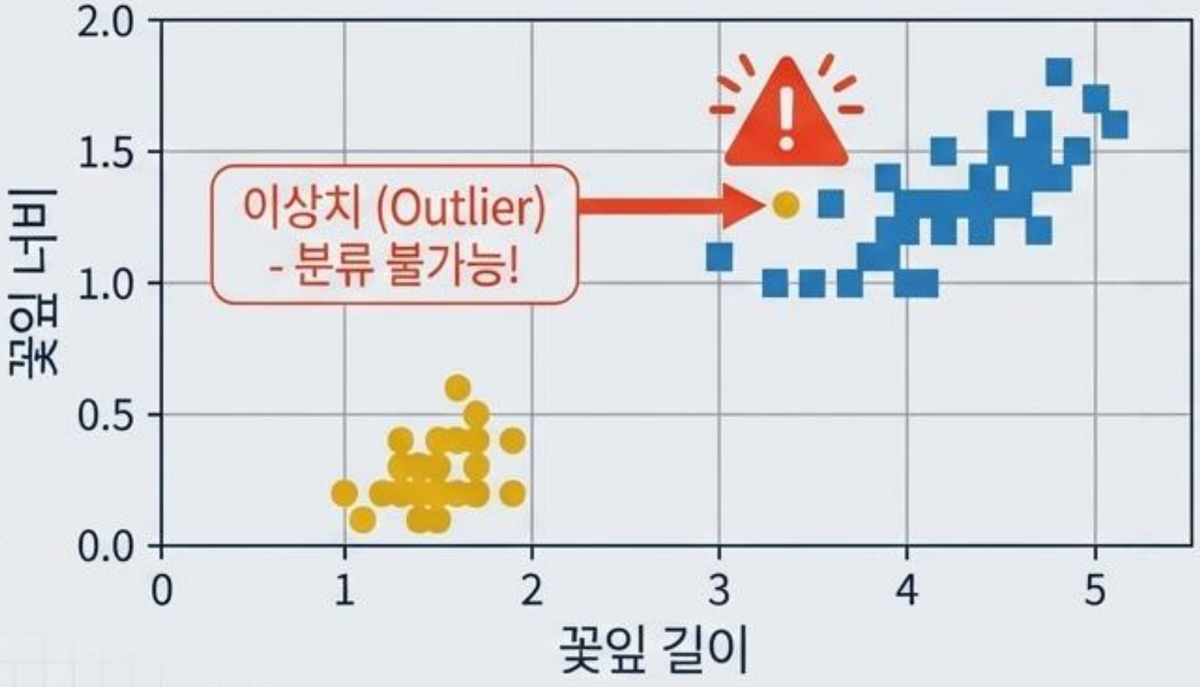

매우 좁고 불안정한 도로 (Narrow, Unstable Road)

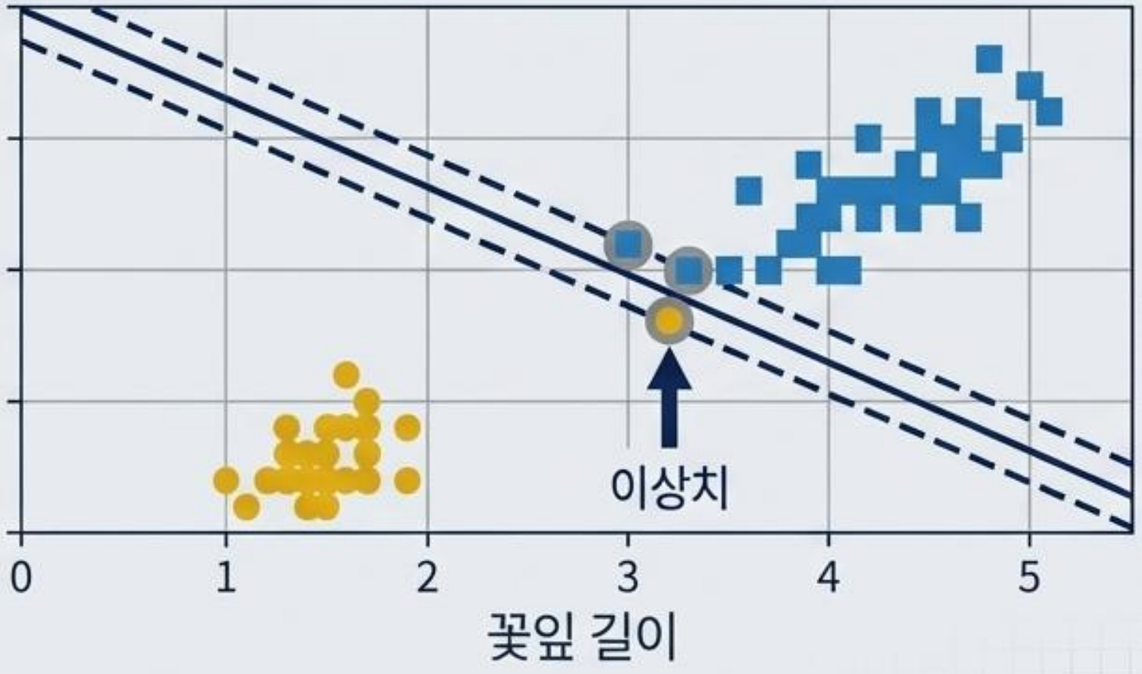

하드 마진의 딜레마

모든 데이터를 완벽하게 나누려다 보면, 이상치(Outlier) 단 하나 때문에 도로를 아예 만들 수 없거나, 도로가 비정상적으로 좁아지게 됩니다. 현실의 데이터는 완벽하게 분리되지 않습니다. 약간의 예외를 허용하는 유연성이 필요합니다.

'C' 다이얼: 도로 폭과 유연성의 완벽한 타협점 찾기

소프트 마진 분류 (Soft Margin): 도로 폭을 넓게 유지하는 것과 마진 오류(도로를 침범하는 데이터) 사이의 균형을 잡는 방식입니다.

C 다이얼 낮춤 (Low C)

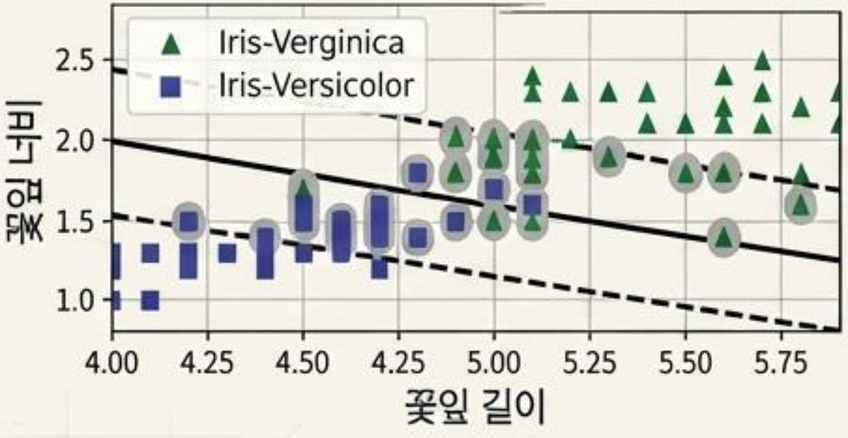

유연해집니다. 도로는 넓어지지만 위반 샘플이 늘어납니다 (과대적합 방지).

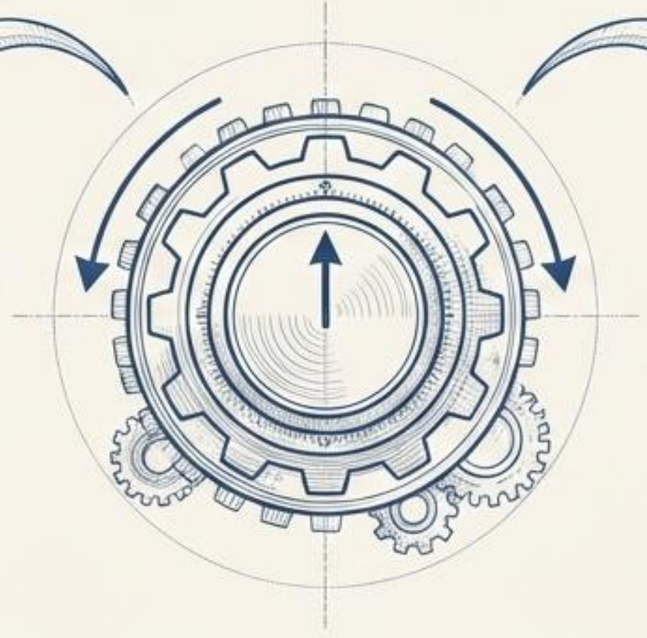

하이퍼파라미터 C
(Hyperparameter C)

C 다이얼 높임 (High C)

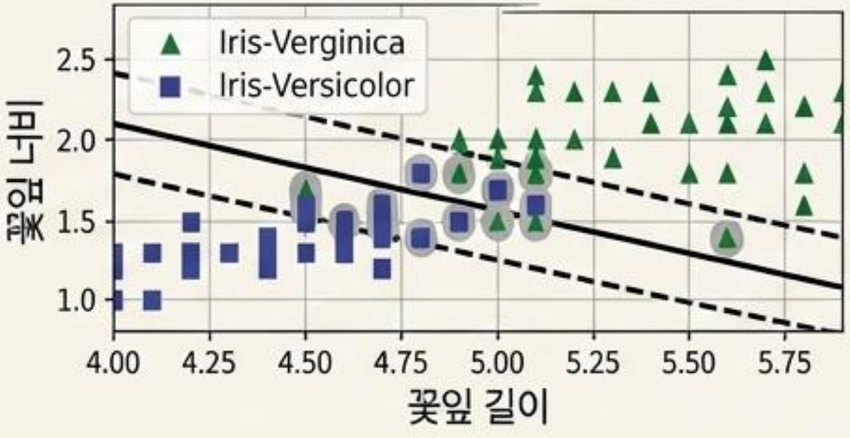

엄격해집니다. 위반 샘플은 줄어들지만 도로는 좁아집니다 (과소적합 방지).

두 번째 난관: 직선으로 나눌 수 없는 얽힌 지형 (비선형 데이터)

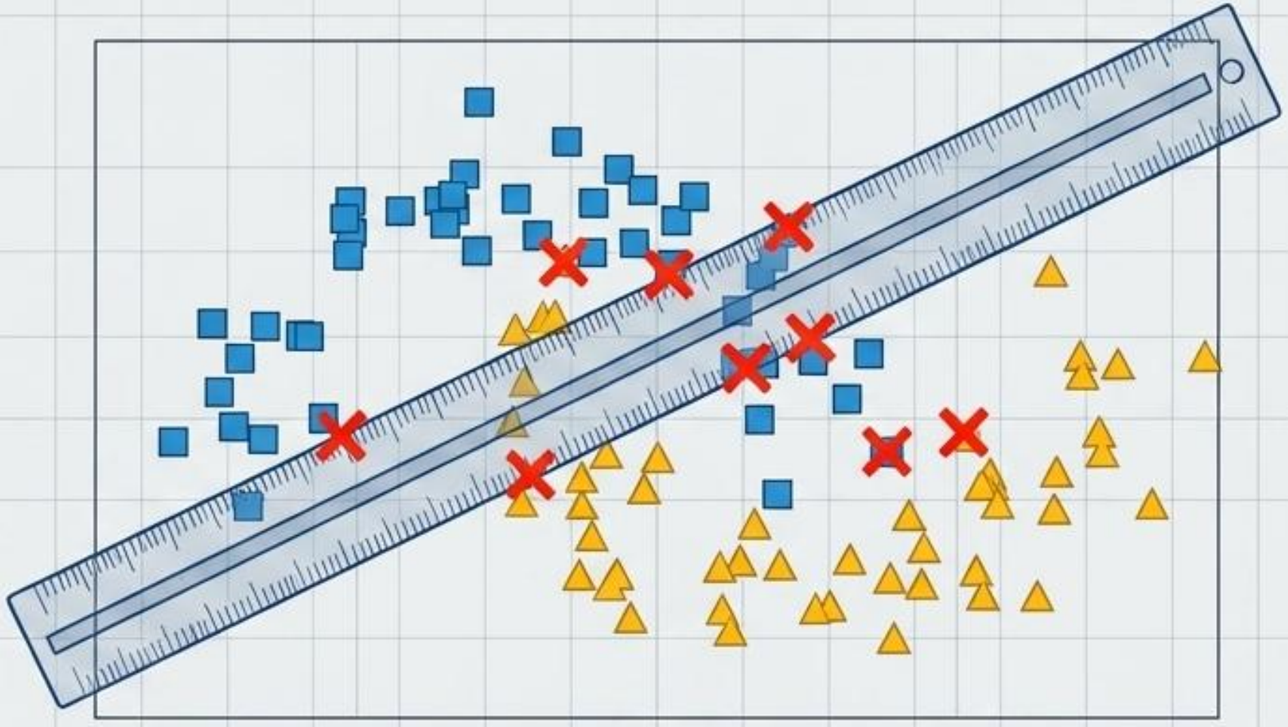

BLUEPRINT NAVY

세상의 많은 데이터는 단순히 직선(선형)으로 깔끔하게 나누어지지 않습니다.

BLUEPRINT NAVY

동그랗게 얽혀 있는 동네를 직선 도로로 나눌 수 있다면 어떻게 해야 할까요? 특성을 변형하는 새로운 차원의 접근이 필요합니다.

해결책 1: 차원의 확장 (다항 특성 추가)

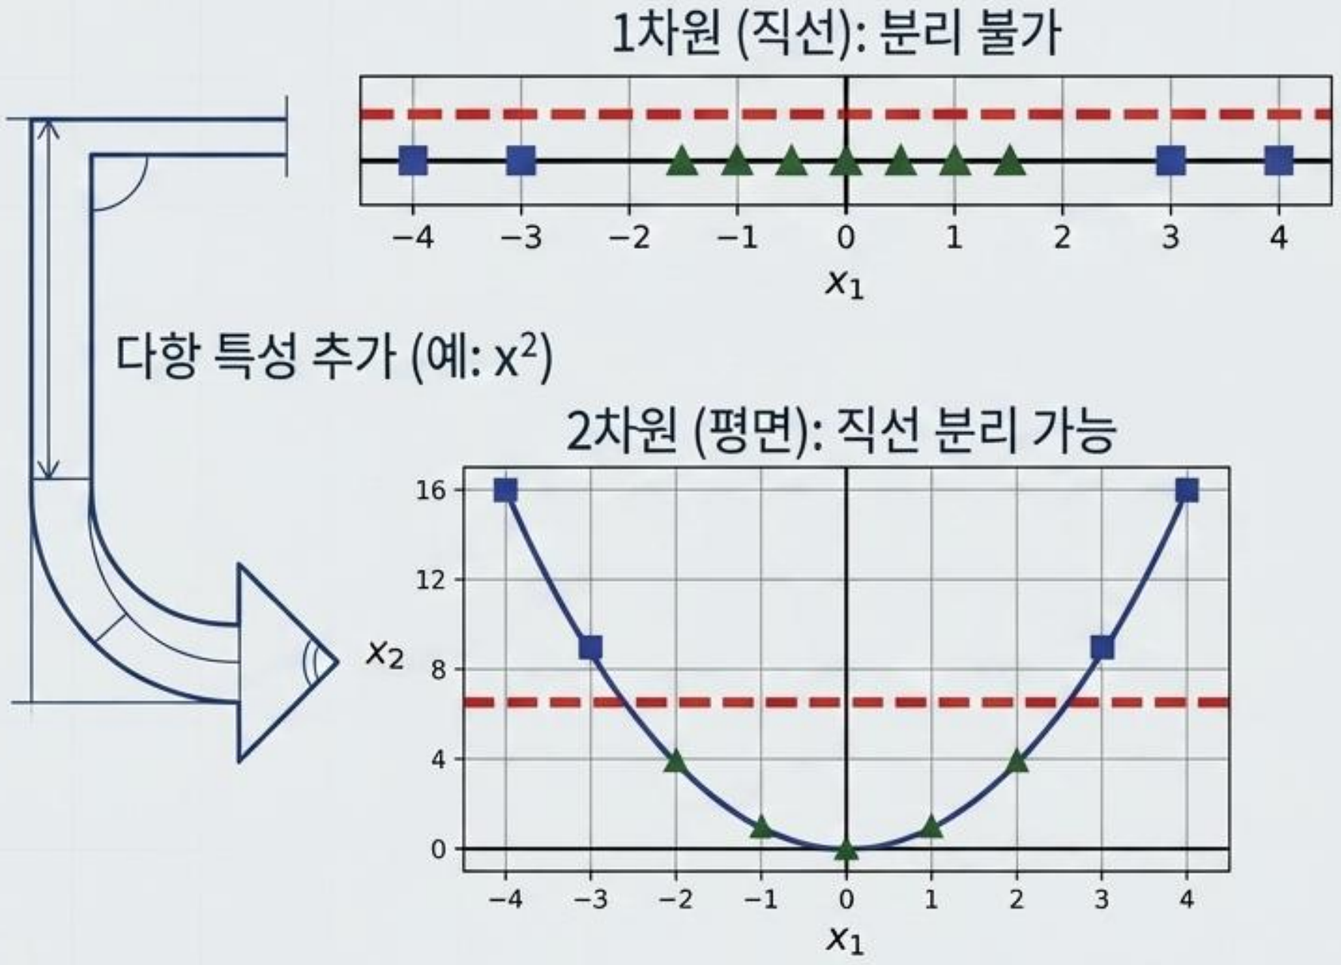

기존 데이터에 새로운 다항 특성을 추가해 차원을 높이면, 얽혀있던 데이터가 곡면으로 펼쳐면서 직선으로 완벽하게 분리할 수 있는 새로운 틈이 생겨납니다.

서포트 벡터 머신의 궁극기: 커널 트릭 (Kernel Trick)

The Problem

The Magic Solution

실제 차원 확장 연산

실제로 데이터를 수천, 수만 개의 고차원으로 일일이 변환하려면 컴퓨터가 견디지 못할 정도로 느려집니다.

커널 트릭의 마법

복잡한 수학적 숏컷을 통해, 실제로 특성을 추가하지 않고도 고차원 특성을 추가한 것과 똑같은 결과를 순식간에 얻어냅니다.

유사도를 활용한 지형 생성: 가우스 RBF 커널

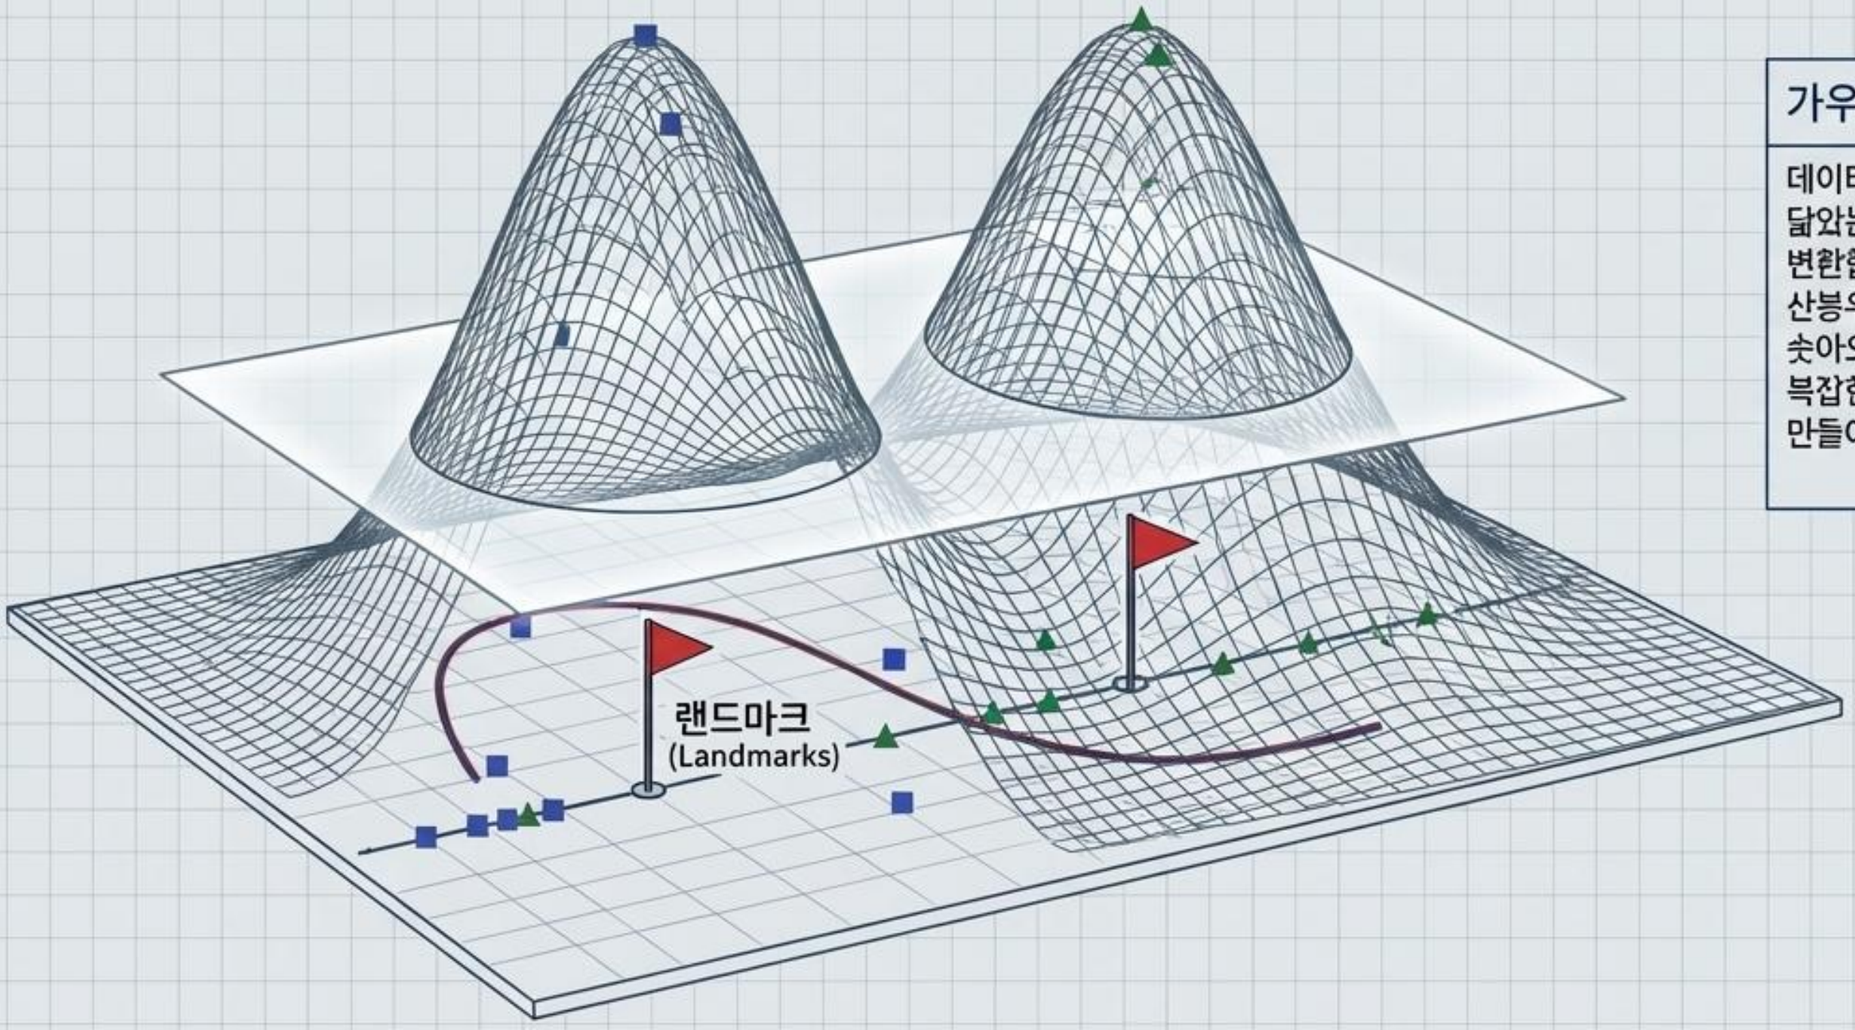

가우스 RBF 커널

데이터가 특정 '랜드마크'와 얼마나 닮았는지(유사도)를 계산하여 고도로 변환합니다. 랜드마크에 가까울수록 산봉우리처럼 높이 솟아오르고, 이 솟아오른 지형의 중간을 자르면 복잡한 곡선의 경계가 자연스럽게 만들어집니다.

발상의 완벽한 전환: SVM 회귀 (Regression)

분류 (Classification): 피해야 할 도로

두 그룹을 가르는 빈 공간(마진)을 최대한 넓게 확보합니다.

회귀 (Regression): 포집해야 할 도로

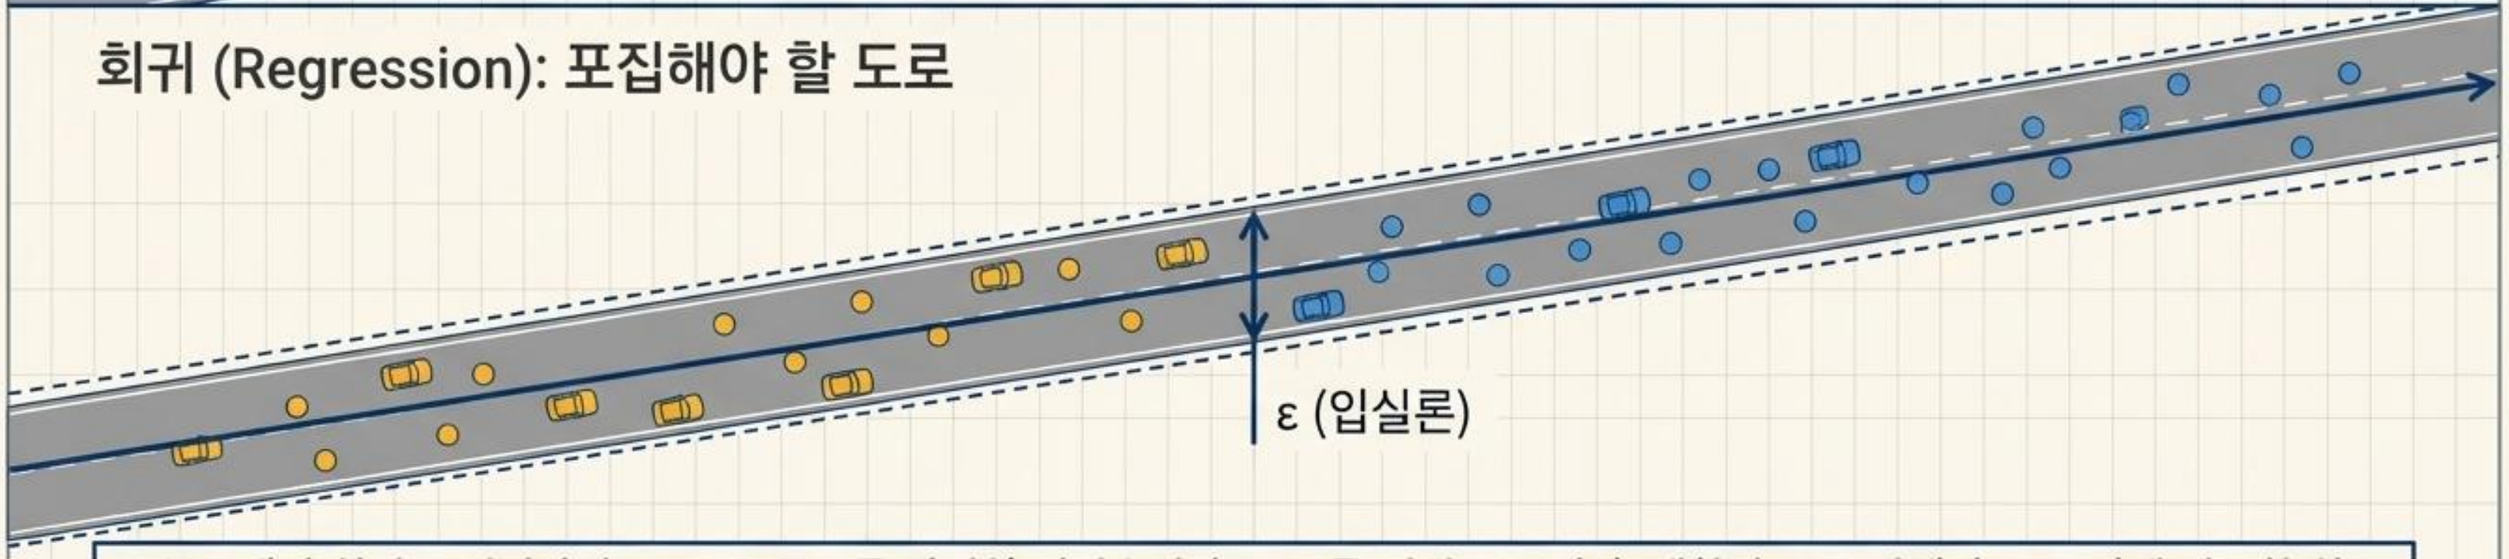

분류에서 회귀로 넘어가면, SVM은 목표를 완전히 뒤집습니다. 도로를 비워두는 대신, 제한된 오류 안에서 도로 안에 가능한 한 많은 샘플이 들어가도록 도로를 포집망처럼 사용합니다. 도로의 폭은 ε (입실론) 다이얼로 세밀하게 조절합니다.

알고리즘 쇼핑 가이드: 나에게 맞는 파이썬 클래스 선택하기

	LinearSVC	SVC	SGDClassifier
시간 복잡도 (속도)	빠름 $O(m \times n)$)	느림 (데이터 커지면 급격히 저하)	빠름 $O(m \times n)$)
커널 트릭 (마법 지원)	지원 안함	지원 (마법 가능!)	지원 안함
추천 사용처	매우 큰 데이터셋에 선형 모델을 적용할 때 추천	비선형 데이터에 강력 추천 (단, 데이터 크기가 적당할 때)	외부 메모리 학습(Out-of-core) 지원. 데이터가 메모리에 다 안 들어갈 때 추천.

실전 SVM 아키텍트를 위한 4가지 황금 법칙

1 스케일링은 선택이 아닌 필수

훈련 전 데이터의 축을 반드시 맞춰라. 스케일링을 생략하면 도로가 찌그러진다.

2 기본은 언제나 선형(Linear)부터

데이터가 크거나 특성이 많다면 가장 빠르고 가벼운 선형 커널을 가장 먼저 시도하라.

3 모델이 과대적합이라면 'C' 다이얼을 내려라

강력한 규제를 가해 유연성을 확보하고, 이상치로 인한 마진 오류를 너그럽게 허용하라.

4 데이터가 얽혀있다면 커널 트릭을 믿어라

직선으로 나눌 수 없는 복잡한 데이터는 다항식 커널이나 가우스 RBF 커널로 차원의 마법을 부려라.